

MANEJO MASIVO DE DATOS

Fuentes y tipos de datos en Big Data


Unidad I: Fundamentos de Big Data

Maltrana Luna Elias Francisco
Montes Rubio Santiago Martin
Salazar Flores Alfonso



¿Qué es una fuente de datos?

Las fuentes de datos son los lugares o medios de donde se obtiene información para posteriormente almacenarla, analizarla y utilizarla



Datos estructurados

Filas y columnas fijas.

Son datos que tienen una estructura definida, normalmente organizados en filas y columnas.

Ejemplos

Bases de datos SQL.

Tablas de clientes.

Registros de ventas.

Información bancaria.

Inventarios.

Ejemplo: exoplanetas.csv

hostname	metodo	año
TOI-707	Transit	2026
Kepler-432	Transit	2015
HAT-P-45	Transit	2014

Datos semiestructurados

Son datos que no tienen una estructura rígida de filas y columnas, pero contienen elementos que permiten identificar y organizar la información.

```
{  
  "center": "HQ",  
  "media_type": "image",  
  "title": "APOLLO 50th",  
  "date_created": "2018-06-18"  
}
```

JSON • XML • APIs

Ejemplo real: un resultado de la biblioteca de imágenes de la NASA. Cada registro puede traer campos distintos y la estructura viaja dentro del propio documento.

Datos no estructurados

Sin un esquema predefinido

Son datos que no siguen una estructura fija.
No pueden organizarse fácilmente en una tabla tradicional.

Ejemplos:
Fotografías.
Videos.
Grabaciones de audio.
Documentos.
Correos electrónicos.
Publicaciones de redes sociales.



Bases de datos

Una base de datos es un sistema que permite almacenar, organizar, consultar y administrar información.

En Big Data pueden utilizarse diferentes tipos de bases de datos.

Ejemplo:

Una tienda puede almacenar:

Clientes.

Productos.

Ventas.

Pagos.

Inventario.

Las bases de datos pueden ser relacionales, como MySQL o PostgreSQL, o NoSQL, utilizadas cuando se manejan grandes cantidades de información flexible o distribuida.



Fuentes comunes de datos

Una API (Application Programming Interface) permite que diferentes programas se comuniquen entre sí y compartan información.

Una aplicación web es un programa que funciona mediante un navegador y permite a los usuarios realizar diferentes actividades, como comprar productos, registrarse, enviar mensajes o consultar información.

Los sensores recopilan información del entorno. IoT consiste en conectar dispositivos a Internet para que puedan recopilar, enviar o recibir información.

Las redes sociales generan enormes cantidades de información.

Los logs son registros que generan automáticamente los sistemas informáticos.

Bases de datos

Aplicaciones web

Sensores / IoT

Redes sociales

Archivos y logs

Ejemplos

Fuente de datos	Ejemplos	¿Qué información genera?
 Bases de datos	MySQL, PostgreSQL, SQL Server	Clientes, productos, ventas, usuarios, inventarios
 Aplicaciones web	Amazon, Mercado Libre, bancos en línea	Búsquedas, compras, inicios de sesión, pagos, clics
 Sensores / IoT	Relojes inteligentes, cámaras, sensores de temperatura, casas inteligentes	Temperatura, ubicación, movimiento, humedad, ritmo de actividad
 Redes sociales	Facebook, Instagram, TikTok, X	Publicaciones, comentarios, likes, fotografías, videos, seguidores
 Archivos y logs	CSV, JSON, registros de servidores	Errores, accesos, eventos, configuraciones, datos

Retos de almacenar y procesar datos en Big Data

- ◆ Gran volumen: se generan enormes cantidades de datos continuamente.
 - ◆ Variedad: existen datos estructurados, semiestructurados y no estructurados.
 - ◆ Velocidad: algunos datos deben procesarse en tiempo real, como transacciones o sensores.
 - ◆ Integración: es necesario combinar información proveniente de diferentes fuentes y formatos.
 - ◆ Calidad: pueden existir datos duplicados, incompletos o con errores.
 - ◆ Seguridad: se debe proteger la información contra accesos no autorizados y pérdidas.
 - ◆ Almacenamiento: se requieren sistemas capaces de guardar grandes cantidades de información de manera eficiente.

Ejemplo

Una empresa puede recibir ventas, imágenes, videos, datos de sensores y registros de usuarios. El reto es almacenar y procesar toda esta información de forma rápida, segura y organizada.



Caso práctico: ciencia espacial

Idea principal del proyecto

¿Cómo integrar datos de diferentes fuentes y formatos en Big Data?

Nuestro proyecto demuestra, mediante un caso de ciencia espacial, cómo se pueden integrar datos reales de NASA y arXiv aunque tengan estructuras diferentes.

Proceso:

5 fuentes → Transformación → Formato común → Dataset integrado

- 📊 Estructurados: CSV de exoplanetas.
- 🔗 Semiestructurados: JSON y XML de APIs de NASA y arXiv.
- 📝 No estructurados: logs del servidor de NASA.
- ↻ Se extraen los datos útiles y se convierten a una misma estructura.
- 📁 Finalmente, las 5 fuentes se combinan en un solo archivo CSV.



Arquitectura y flujo del proyecto

Cómo funciona el programa?

1. Recopila los datos

Lee 5 fuentes diferentes: CSV, JSON, XML, LOG y API.

2. Analiza las fuentes

Identifica el tipo de dato, número de registros, campos disponibles y valores faltantes.

3. Transforma los datos

Extrae la información importante y la convierte a un formato común.

4. Integra la información

Une las 5 tablas utilizando las mismas columnas:

id | fuente | entidad | tipo_contenido | valor | fecha


5. Genera el resultado

Crea un único archivo dataset_integrado.csv y muestra un resumen de los datos.

Arquitectura del flujo de datos

Caso: ciencia espacial, datos abiertos reales de la NASA

Diagrama del proyecto



Demostración funcionando



45,322 registros integrados

Las 5 fuentes en una sola tabla. Hay valores faltantes reales, como 36,690 planetas sin radio o masa.

```
efml@efml-HP-Laptop-15-ef2xxx: ~/Documents/BIG DATA/Proyecto y exposición — Unidad I: Fundamentos de Big Data
~/Documents/BIG DATA/Proyecto y exposición — Unidad I: Fundamentos de Big Data

XML-arxiv      20

Tipos de datos por columna (dtype de pandas):
id              str
fuente          str
entidad         str
tipo_contenido str
valor          float64
fecha          str

Valores faltantes por columna en el dataset ya integrado:
id              0
fuente          0
entidad         0
tipo_contenido 0
valor          0
fecha          0

Vista previa del dataset integrado:
      id      fuente      entidad tipo_contenido      valor fecha
TOI-707 b CSV-exoplanetas TOI-707      Transit  2.398271  2026
Kepler-317 c CSV-exoplanetas Kepler-317      Transit  0.000000  2014
Kepler-1513 b CSV-exoplanetas Kepler-1513      Transit  8.594000  2016
HAT-P-45 b CSV-exoplanetas HAT-P-45      Transit  0.000000  2014
KMT-2021-BLG-1898L b CSV-exoplanetas KMT-2021-BLG-1898L      Microlensing  0.000000  2022
HATS-10 b CSV-exoplanetas HATS-10      Transit 12.543059  2015
NGTS-1 b CSV-exoplanetas NGTS-1      Transit  0.000000  2017
Kepler-432 b CSV-exoplanetas Kepler-432      Transit 11.955000  2015
Kepler-1181 b CSV-exoplanetas Kepler-1181      Transit  0.000000  2016
Kepler-106 d CSV-exoplanetas Kepler-106      Transit  1.360000  2014

Dataset integrado guardado en: /home/efml/Documents/BIG DATA/Proyecto y exposición – Unidad I: Fundamentos de Big Data/data/dataset_integrado.csv

RESULTADO FINAL
Listo: las 5 fuentes (CSV, JSON, XML, log y API) quedaron en un solo dataset.
Entidad mas frecuente: kristina.az.com
(base) efml@efml-HP-Laptop-15-ef2xxx:~/Documents/BIG DATA/Proyecto y exposición – Unidad I: Fundamentos de Big Data$
```

Conclusiones

El proyecto permitió demostrar que en Big Data la información puede provenir de diferentes fuentes y presentarse en distintos formatos, como CSV, JSON, XML y logs. Para poder analizarlos en conjunto, es necesario extraer, transformar y estandarizar los datos.

Mediante Python y sus diferentes librerías, logramos integrar 5 fuentes reales de NASA y arXiv en un solo dataset, identificando también datos faltantes y diferencias entre las estructuras. Esto demuestra que uno de los principales retos de Big Data es convertir información heterogénea en datos organizados y útiles para su análisis.